

5.000 Film, 26 Özellik, Tek Soru

TMDB Hit Classifier — Bir filmin gişe rekortmeni olup olmayacağını vizyona girmeden önce tahmin edebilir miyiz?

3.229

Toplam Film

Bütçe ve hasılat verisi olan, analize dahil
edilen film sayısı

1.176

Gişe Hiti (%36)

Enflasyon düzeltmeli hasılatı \$100M'ı aşan
filmler

2.053

Gişe Miss (%64)

Enflasyon düzeltmeli hasılatı \$100M'ın
altında kalan filmler

Ham Veriden Anlam Çıkarmak

Veri Kaynağı & Filtreleme

Kaggle TMDB-5000 veri seti — 2 tablo birleştirildi:

TMDB 5000 Movies → Bütçe, hasılat, tür, anahtar kelimeler

TMDB 5000 Credits → Yönetmen, oyuncu kadrosu

Bütçe > 0 → 4.803 film ve Hasılat > 0 → **3.229 film** kaldı

Hit Tanımı (Kritik Karar)

Nominal fiyatlarla ölçüm yanıltıcı. Tüketici Fiyat Endeksi (CPI) ile enflasyona göre düzeltme yapıldı (2010 baz yılı).

⚠ **HIT** = CPI-düzeltilmeli hasılat $\geq$ \$100M (2010 dolar bazlı) → %36 pozitif sınıf (1.176 hit, 2.053 miss)

Zamansal Bölünme (Sızdırmazlık)


Veri sızıntısını önlemek için kronolojik bölünme uygulandı:

Küme	Yıllar	Film Sayısı	Hit Oranı
Eğitim	1916–2013	2.901	%36
Doğrulama	2014–2015	256	%41
Test	2016	72	%47

Kronolojik bölünme sayesinde model gelecekteki filmleri tahmin ederken geçmiş veriden öğreniyor — gerçek dünya senaryosunu yansıtıyor.

Para mı, Tür mü Belirliyor?


Bütçe Dilimine Göre Hit Oranı



Bütçe büyüdükçe hit olasılığı belirgin biçimde artar — ancak tek başına yeterli değildir.

\$100M (2010 dolar), veri setindeki tipik filmin başabaş noktasıdır — bu eşiği geçen \$100–200M bütçeli filmlerin %90'ı hit.

Film Türüne Göre Hit Oranı (%)



Animasyon ve macera filmleri, korku ve belgesellere göre yaklaşık **8 kat** daha fazla hit üretiyor.

Zaman ve Deneyim Fark


Yaratıyor

Yıllık Hit Oranı Trendi (1916–2016)



Hit oranı 2010 sonrası zirve noktasına ulaştı — stüdyolar artık riski düşük, getirisi yüksek dev projelere odaklanıyor.

Yönetmen Deneyimi x Hit Oranı (%)



Deneyimsiz yönetmenlerle kıyaslandığında, 10+ film yönetmenlerin hit oranı **2.5 kat** daha yüksek.

Neden Bu Algoritmalar?

26 Özelliğin Tam Listesi

Özellik	Açıklama
budget_adjusted	Enflasyona göre düzeltilmiş prodüksiyon bütçesi (2010 dolar)
runtime	Film süresi (dakika)
num_companies	Yapım şirketi sayısı
is_major_studio	Büyük stüdyo mu? (Warner, Disney, Universal...)
is_us_production	ABD yapımı mı?
has_homepage	Resmi web sitesi var mı? (pazarlama bütçesinin göstergesi)
num_genres	Filme atanan tür sayısı
is_franchise	Bir serinin parçası mı? (Marvel, Harry Potter vb.)
is_summer	Yaz döneminde mi vizyona girdi? (Haziran–Ağustos)
is_holiday	Tatil döneminde mi vizyona girdi? (Kasım–Aralık)
director_film_count	Yönetmenin bu filmden önce çektiği uzun metraj sayısı
director_collab_count	Yönetmenin kariyerindeki farklı oyuncu/ekip işbirliği sayısı
actor_hist_roi	İlk 3 başrol oyuncusunun önceki filmlerinin ortalama gişe getiri katsayısı (revenue/budget)
company_hist_roi	En güçlü yapım şirketinin önceki filmlerinin gişe getiri katsayısı (revenue/budget)
monthly_franchise_density	O ay vizyona giren franchise film oranı (rekabet yoğunluğu)
genre_Action	Aksiyon filmi mi?
genre_Adventure	Macera filmi mi?
genre_Animation	Animasyon mu?
genre_Documentary	Belgesel mi?
genre_Drama	Drama mı?
genre_Family	Aile filmi mi?
genre_Fantasy	Fantastik mi?
genre_Horror	Korku filmi mi?
genre_Science Fiction	Bilim kurgu mu?
kw_independent_film	Bağımsız yapım olarak etiketlenmiş mi?
kw_sequel	Bir önceki filmin devamı mı?

Ensemble Modeli: LightGBM + CatBoost → Soft Voting

Algoritma	Neden Seçildi
LightGBM	Hızlı, küçük veri setlerinde güçlü, histogram tabanlı gradient boosting
CatBoost	Gürültülü özelliklere karşı dayanıklı, ordered boosting ile overfitting önleme
Soft Voting	İki modelin zayıflıklarını dengeler, olasılık ortalaması alır

Optimizasyon Metriği: F2 Skoru — Recall ağırlıklı → Hit kaçırmak, yanlış pozitiften daha maliyetli. Optuna ile 100 deneme → En iyi hiperparametreler seçildi.



Modelin Karne Günü

0.857

Test F2 Skoru

Recall ağırlıklı ana metrik — hit kaçırmayı minimize eder

0.915

ROC-AUC

Sınıflandırma gücünün genel ölçüsü

0.922

PR-AUC


Precision-Recall eğrisi altındaki alan — dengesiz sınıflar için kritik

0.88

Recall


Gerçek hitlerin %88'i doğru yakalandı

Overfitting Kontrolü



Train F2=0.77 → Val F2=0.82 → Test F2=0.86 — model ezberlemiyor, dağılım kaymasıyla birlikte genelleniyor

Gişe Başarısı İçin En Etkili 10 Faktör



Model Bu Filmleri Nasıl Değerlendirir?

✓ HIT — %97.0

Avatar (2009)

- Fox büyük stüdyo
- \$237M yüksek bütçe
- Cameron'ın 5. filmi
- Tatil sezonu vizyonu (Aralık)

✓ HIT — %96.2

The Dark Knight (2008)

- Warner Bros büyük stüdyo
- \$185M yüksek bütçe
- Nolan'ın 6. filmi
- Franchise (Batman serisi)
- Yaz sezonu vizyonu (Temmuz)

✗ MISS — %16.3

Paranormal Activity (2007)

- \$15.000 mikro bütçe
- Yeni yönetmen (0 film)
- Bağımsız yapım
- Eğitim setinde bu tür aykırı başarılar çok nadir

⚠ **Modelin Gerçek Sınırı:** Paranormal Activity gerçekte **\$15.000 bütçeyle \$193M hasılat** yaptı. Yatırılan **her 1 dolar için 12.890 dolar** geri döndü — tarihin en yüksek getirili filmlerinden biri. Model bu "düşük bütçe viral isabet" örüntüsünü öngöremedi: eğitim setinde bu tür aykırı başarılar çok nadir. Modelin gerçek sınırı burada.